

Proyecto 1: Sistema de Inteligencia de Negocios SG-Food

Daniel Eduardo Velásquez Avila **Carnet:** 202200041

Índice

1. Introducción
 - a. 1.1. Objetivos del Proyecto
 - b. 1.2. Tecnologías Utilizadas
2. Definición del Modelo de Datos (Data Warehouse)
 - a. 2.1. Arquitectura: Modelo Constelación (Galaxia)
 - b. 2.2. Granularidad de los Datos
 - c. 2.3. Diccionario de Datos Histórico
3. Fases del Proceso ETL (Integration Services)
 - a. 3.1. Fase 0: Idempotencia y Preparación
 - b. 3.2. Fase 1: Extracción y Staging Area
 - c. 3.3. Fase 2: Transformación y Limpieza (Reglas de Negocio)
 - d. 3.4. Fase 3: Carga (Carga de Dimensiones y Hechos)
4. Validaciones de Integridad y Calidad de Datos
5. Implementación del Cubo OLAP (Analysis Services)
 - a. 5.1. Configuración del DSV y Medidas
 - b. 5.2. Diseño de Jerarquías Analíticas
 - c. 5.3. Relaciones y Procesamiento (Deployment)
6. Conclusiones y Lecciones Aprendidas

1. Introducción

El presente documento detalla el diseño, desarrollo e implementación de una solución integral de Inteligencia de Negocios (BI) para la empresa SG-Food. Ante la necesidad de consolidar información histórica de compras y ventas que presentaba serios problemas de calidad y formato (sabotaje de datos), se construyó un Data Warehouse centralizado que permite a los tomadores de decisiones cruzar métricas operativas de forma rápida y confiable a través un Cubo OLAP.

1.1. Objetivos del Proyecto

- **General:** Construir una solución End-to-End de Business Intelligence que consolide los procesos de compras y ventas de SG-Food en un solo entorno analítico multidimensional.
- **Específicos:**
 - Diseñar un modelo capaz de soportar comparativas entre múltiples procesos transaccionales sin duplicar dimensiones maestras.
 - Desarrollar un flujo ETL automatizado que depure anomalías estructurales severas en los archivos planos de origen (fechas malformadas, negativos, espacios en blanco).
 - Desplegar un Cubo OLAP interactivo mediante jerarquías (Drill-down y Roll-up) para un fácil consumo del negocio.

1.2. Tecnologías Utilizadas

- **Motor Relacional:** SQL Server 2025 Developer Edition (Almacenamiento del Data Warehouse y esquema de Staging).
- **ETL:** Visual Studio 2022 con extensión SQL Server Integration Services (SSIS).
- **OLAP:** SQL Server Analysis Services 2022 (SSAS) en modo Multidimensional.
- **Procesamiento:** Transact-SQL (T-SQL) para limpiezas avanzadas y validación de llaves.

2. Definición del Modelo de Datos (Data Warehouse)

2.1. Arquitectura: Modelo Constelación (Galaxia)

Para satisfacer los requerimientos analíticos exigidos por SG-Food, se descartó el tradicional esquema de Estrella (Star Schema) en favor de un **Modelo de Constelación de Hechos (Fact Constellation)**. El negocio exigía analizar dos procesos totalmente distintos (Ventas vs Compras), por lo que esta arquitectura despliega dos tablas de hechos independientes (Fact_Ventas y Fact_Compras) orbitando alrededor de "Dimensiones Conformadas" compartidas, tales como

Dim_Tiempo, Dim_Producto y Dim_Sucursal. Esto permite un cruce de indicadores limpio sin sobrecargar la Base de Datos.

2.2. Granularidad de los Datos

El grano definido para ambas tablas de hechos transaccionales es la **línea de detalle por transacción diaria**. Cada registro almacena la agregación más profunda posible (compra/venta de un producto específico, en una sucursal y día específico), lo que asegura la máxima flexibilidad analítica al escalar en el cubo OLAP.

2.3. Diccionario de Datos Histórico

- **Tablas de Hechos (Fact Tables):**
 - Fact_Ventas: Almacena métricas comerciales de salida. Medidas cuantitativas: Unidades y PrecioUnitario.
 - Fact_Compras: Almacena métricas de reabastecimiento. Medidas cuantitativas: Unidades y CostoUnitario.
- **Dimensiones Compartidas (Conformed Dimensions):**
 - Dim_Tiempo: Dimensión generada transaccionalmente a partir de fechas válidas (Día, Mes, Año).
 - Dim_Producto: Atributos descriptivos normalizados (Nombre, Marca, Categoría).
 - Dim_Sucursal: Permite el análisis geográfico (Región, Departamento, Sucursal).
- **Dimensiones Exclusivas:**
 - Dim_Cliente y Dim_Vendedor: Conectadas únicamente al proceso de Ventas.
 - Dim_Proveedor: Conectada únicamente al proceso de Compras.

3. Fases del Proceso ETL (Integration Services)

El proceso de Extracción, Transformación y Carga (ETL) debió enfrentar archivos .csv gravemente corrompidos de forma intencional; para ello se utilizó una arquitectura robusta de limpieza en dos capas.

3.1. Fase 0: Idempotencia y Preparación

El diseño del *Control Flow* asegura que el paquete no duplique información si el usuario presiona "Start" múltiples veces. El primer paso del flujo es un contenedor Execute SQL Task que ejecuta un truncado/eliminación (DELETE) respetando la Integridad Referencial: vaciando primero las tablas de hechos (Fact_Ventas y Fact_Compras) y posteriormente los catálogos dimensionales (Dim_Cliente, etc.).

3.2. Fase 1: Extracción y Staging Area

Los datos planos se leyeron mediante *Flat File Managers*. Dada la severidad del "ruido" en los datos que los componentes nativos de SSIS (como el "Sort" o "Derived Column") no pueden procesar eficientemente sin colapsar la memoria caché, los datos crudos se cargaron en un **Área de Staging** (tablas temporales tmp_Ventas y tmp_Compra), delegando la limpieza intensiva al motor T-SQL.

3.3. Fase 2: Transformación y Limpieza (Reglas de Negocio)

Dentro del Data Warehouse (en el nivel de Staging), se programaron reglas estrictas de limpieza y transformación:

1. **Infiltración de Letras en Fechas (Z3/08/2018):** Se descubrieron fechas corrompidas con la letra 'Z'. Se normalizaron forzando un reintegro matemático con la función envolvente: `TRY_CONVERT(DATE, REPLACE(UPPER(TRIM(Fecha)), 'Z', '2'), 103)`. Esta validación garantizó que únicamente Fechas con formato británico (103) pasaran a Dim_Tiempo.
2. **Valores Unitarios Negativos y Faltantes:** Se filtraron montos irreales utilizando T-SQL condicional explícito en los *INSERT* de migración: `(Unidades > 0 AND PrecioUnitario > 0)` y se descartó la asimilación de proveedores sin identificador: `(CodProveedor IS NOT NULL AND CodProveedor <> 'Sin código')`.
3. **Sensibilidad a Mayúsculas y Blancos:** Todo texto dimensional fue pasado por la combinación `UPPER(TRIM(Campo))` para evitar que "Bebidas " y "bebidas" generaran duplicados de *Primary Key* en SSIS.

3.4. Fase 3: Carga (Carga de Dimensiones y Hechos)

Posterior a la limpieza, los registros catalogados se ingresaron a sus respectivas Dimensiones usando la función `NOT IN (SELECT...)` para almacenar únicamente IDs faltantes. Por último, las métricas limpias se vertieron sobre las tablas Fact_Ventas y Fact_Compras.

4. Validaciones de Integridad y Calidad de Datos

Para demostrar la eficacia del sistema, se codificaron consultas de validación en el archivo `consultas_validacion.sql`.

- Se realizó un barrido matemático (`SELECT COUNT(*)`) sobre las tablas de dimensiones descartando una migración nula.

- Se corrió la consulta `SELECT TOP 10 * FROM Fact_Ventas WHERE CodCliente IS NULL OR CodProducto IS NULL`; para probar empíricamente que no existe ninguna Venta "huérfana" o desconectada de un maestro en la Constelación.

5. Implementación del Cubo OLAP (SSAS)

Cumplido el ciclo ETL, la Base de Datos se conectó a **SQL Server Analysis Services (SSAS)**.

5.1. Configuración del DSV y Medidas

Se construyó un *Data Source View (DSV)* conector de 8 tablas. Dentro del Cubo, el sistema reconoció fluidamente la arquitectura dividiéndose en dos *Measure Groups* (Grupos de Medida): Compras y Ventas.

5.2. Diseño de Jerarquías Analíticas

Para potenciar la navegabilidad del negocio mediante operaciones Drill-down/Drill-up, se definieron manualmente las siguientes jerarquías dentro de las dimensiones:

- **Geografía Comercial (Dim Sucursal):** Región -> Departamento -> Sucursal.
- **Cronología de Negocio (Dim Tiempo):** Año -> Mes -> Día.

5.3. Relaciones y Procesamiento (Deployment)

- **Resolución de Bugs de Compatibilidad:** Al encontrarse trabajando bajo *Developer Edition 2025*, el cliente de Visual Studio rechaza la cadena "StandardDeveloper64". Esto se solucionó implementando un motor paralelo SSAS versión 2022 y ajustando el *Target Server* del proyecto.
- **Seguridad OLAP:** La conectividad OLE DB entre SSAS y el SQL Server se autorizó configurando el *Impersonation Mode* del Data Source bajo credenciales de administrador para permitir la carga masiva ("Process Full").