

Universidad San Carlos de Guatemala

Facultad de ingeniería.

Ingeniería en ciencias y sistemas



FIUSAC
FACULTAD DE INGENIERÍA
UNIVERSIDAD DE SAN CARLOS DE GUATEMALA



Proyecto 2:

Procesamiento y Análisis Exploratorio de Datos Masivos en BigQuery

PONDERACIÓN: 25 pts

Tiempo estimado: 22 hrs

1. MARCO FORMATIVO	3
1.1. Valor	3
1.2. Competencia(s)	3
1.3. Objetivo SMART	4
2. Resumen Ejecutivo	5
3. Enunciado del Proyecto	5
3.1 Descripción del problema a resolver	5
3.2 Alcance del proyecto	5
3.3 Requerimientos técnicos	6
3.4 Entregables	6
4. Material de apoyo	6
5. Metodología	7
6. Recursos y herramientas a utilizar	7
7. Desarrollo de Habilidades Blandas	8
8. Cronograma	8
9. Rúbrica de Calificación	9
9.1 Requisitos para optar a la calificación	9
9.2 Resumen de Puntuaciones	10
9.3 Comentarios Generales	10
9.4 Detalle de la Calificación	11

1. MARCO FORMATIVO

1.1. Valor

Nombre del valor	¿Cómo se aplica en tu laboratorio?
Rigor analítico y responsabilidad profesional	Uso correcto del dataset público, ejecución eficiente de consultas SQL, optimización responsable de recursos en la nube y documentación transparente de hallazgos.

1.2. Competencia(s)

Tipo de Competencia	General y específicas
Competencia General	Maneja e interpreta adecuadamente datos masivos, sean estos estructurados o no estructurados, facilitando su visualización e interpretación de forma eficaz en apoyo a la toma de decisiones.
Competencia Específica	Administra proyectos de análisis de datos en la nube con herramientas como BigQuery y Google Cloud Platform aplicando principios de gobierno de datos, seguridad y control de acceso.

1.3. Objetivo SMART

SMART	Definición	Objetivo redactado
Específico (¿Qué?)	El objetivo es concreto y tangible.	Diseñar e implementar un proceso de análisis exploratorio sobre el dataset público NYC Taxi Trips 2022 en BigQuery, aplicando consultas SQL, tablas derivadas, particiones y clustering para identificar patrones relevantes.
Medible (¿Cuánto?)	El objetivo tiene una medida objetiva de éxito.	Se considerará cumplido al entregar consultas SQL funcionales, evidencia de optimización en bytes procesados, un informe visual con 3 visualizaciones y un README técnico con hallazgos documentados.
Alcanzable (¿Cómo?)	El objetivo debe ser posible con los recursos disponibles.	El objetivo puede lograrse con una cuenta activa de Google Cloud Platform, BigQuery, Google Sheets o Looker Studio y un repositorio organizado en GitHub.
Realista (¿Para qué?)	El objetivo contribuye a metas más amplias.	Fortalece las competencias en análisis de datos masivos, optimización de consultas, documentación técnica y comunicación de hallazgos en entornos de analítica en la nube.
A Tiempo (¿Cuándo?)	El objetivo tiene fecha límite o mejor aún un cronograma de hitos de progreso	Debe entregarse según el cronograma oficial del proyecto: asignación el 08 de abril, entrega el 29 de abril.

2. Resumen Ejecutivo

En esta fase, los estudiantes trabajarán con el dataset público New York City Taxi Trips 2022, disponible en Google BigQuery, que contiene más de 100 millones de registros de viajes de taxi en la ciudad de Nueva York.

El proyecto busca desarrollar competencias en análisis exploratorio de datos masivos utilizando SQL en BigQuery, aplicando técnicas de transformación y optimización de consultas mediante particiones y clustering, y comunicando hallazgos relevantes mediante visualizaciones iniciales.

Utilizando BigQuery ML, se entrenarán al menos 2 modelos distintos de regresión o clasificación, se evaluará su desempeño mediante métricas como precisión, error cuadrático medio o matriz de confusión, y se aplicará sobre nuevos datos. Finalmente, se construirá un tablero en Google Data Studio para comunicar visualmente los resultados y sus implicaciones.

3. Enunciado del Proyecto

3.1 Descripción del problema a resolver

El análisis de grandes volúmenes de datos representa un reto cuando las consultas son lentas, costosas o difíciles de interpretar. En este proyecto se utilizará el dataset público NYC Taxi Trips 2022 en BigQuery, con más de 100 millones de registros, para transformar datos masivos en información útil.

El estudiante deberá diseñar consultas SQL, aplicar técnicas de optimización mediante particiones y clustering, identificar patrones significativos de viaje, costo y comportamiento de usuarios, y presentar hallazgos mediante visualizaciones exploratorias claras.

3.2 Alcance del proyecto

Obligatorio:

- Conectarse al dataset público
bigquery-public-data.new_york_taxi_trips.tlc_yellow_trips_2022.
- Realizar consultas SQL avanzadas para calcular métricas descriptivas, analizar distribuciones categóricas y detectar patrones temporales.
- Crear tablas derivadas en su propio proyecto para trabajar subconjuntos optimizados del dataset.
- Implementar particiones por fecha y clustering por ubicaciones para reducir el costo de procesamiento.
- Comparar el rendimiento de las consultas antes y después de aplicar optimización.
- Exportar o enlazar resultados a Google Sheets o Looker Studio para generar al menos 3 visualizaciones exploratorias.

- Documentar el proceso en un repositorio organizado, incluyendo scripts SQL, capturas de consultas, evidencias e informe visual.
- Usar BigQuery ML para entrenar al menos 2 modelo predictivo sobre un dataset limpio.
- Implementación y comparación entre modelos con distintas métricas de evaluación e hiperparametros (como ROC-AUC, RMSE, matriz de confusión o iteraciones)
- Manejo de data leakage por data_split_eval_fraction y split personalizado.
- Ejecutar predicciones sobre nuevos registros.
- Representar resultados y hallazgos de los modelos mediante visualizaciones en el dashboard.

3.3 Requerimientos técnicos

- **Herramientas:** Google Cloud Platform (GCP), Google BigQuery, Google Sheets o Looker Studio y GitHub.
- **Dataset:** bigquery-public-data.new_york_taxi_trips.tlc_yellow_trips_2022.
- **Consultas:** uso de funciones agregadas, funciones temporales, filtros, agrupaciones y transformaciones SQL.
- **Optimización:** implementación de particiones (por fecha) y clustering (por pickup_location_id y dropoff_location_id).
- **Conocimientos aplicados:** análisis exploratorio de datos masivos, optimización de consultas y comunicación visual de hallazgos.

3.4 Entregables

Tipo	Descripción
Scripts SQL	Archivo(s) .sql con las consultas realizadas en BigQuery para exploración, transformaciones y optimización. Deben estar comentados para explicar la finalidad de cada bloque.
Scripts Big Query ML	Script SQL del modelo entrenado y evaluado y tablas de resultados con predicciones.
Evidencias	Capturas de pantalla de consultas relevantes en BigQuery, conteo de registros, aplicación de particiones/clustering y evidencia de reducción de bytes procesados.

Informe visual	Enlace a un tablero de Looker Studio o archivo de Google Sheets enlazado a BigQuery, con al menos 3 visualizaciones exploratorias de hallazgos clave y la comparación de al menos 2 predicciones con los modelos de ML (Rolling Forecast)
Archivo README	Documento técnico con nombre del proyecto, dataset utilizado, transformaciones realizadas, técnicas de optimización aplicadas, comparación de desempeño (optimizado vs estándar), hallazgos relevantes, explicación de los modelos de regresión o clasificación en BigQuery ML, enlace al informe visual.
Repositorio del curso	Carpeta Proyecto_2 dentro del repositorio del curso, con scripts, evidencias, README y materiales organizados con nombres consistentes y estructura clara.

4. Material de apoyo

- Documentación oficial de BigQuery <https://cloud.google.com/bigquery/docs>
- Documentación de BigQuery Public Datasets <https://cloud.google.com/bigquery/public-data>
- Guías de particiones, clustering y Looker Studio <https://cloud.google.com/bigquery/docs/partitioned-tables>

5. Metodología

1. Conexión y exploración inicial del dataset:

Acceder al dataset público en BigQuery, validar registros y comprender la estructura de las tablas y variables disponibles.

2. Desarrollo de consultas SQL y transformaciones:

Construir consultas para filtrar, agrupar, calcular métricas y preparar datos útiles para el análisis exploratorio.

3. Optimización del procesamiento:

Crear tablas derivadas, aplicar particiones y clustering, y comparar costos de procesamiento antes y después de la optimización.

4. Visualización y análisis de hallazgos:

Generar visualizaciones exploratorias en Google Sheets o Looker Studio para resumir patrones clave del dataset.

5. Documentación final:

Elaborar un repositorio organizado con scripts SQL, evidencias, README técnico y conclusiones relevantes del análisis.

6. Recursos y herramientas a utilizar

Software:

- Google Cloud Platform y Google BigQuery
- Google Sheets o Looker Studio

Plataformas:

- GitHub (para repositorio del proyecto)
- Google Cloud Console (para ejecución y monitoreo de consultas)

Lecturas recomendadas:

- Documentación oficial de BigQuery y datasets públicos.
- Guías de particiones, clustering y optimización de consultas.
- Material de apoyo para visualización de resultados en Google Sheets o Looker Studio.

7. Desarrollo de Habilidades Blandas

En este proyecto se promueven competencias transversales orientadas al análisis responsable, eficiente y comunicable de datos masivos:

- **Pensamiento analítico:** interpretación crítica de patrones, tendencias y métricas obtenidas a partir de consultas SQL sobre grandes volúmenes de datos.
- **Responsabilidad en el uso de recursos cloud:** optimización consciente de consultas para reducir costos de procesamiento y uso eficiente de la plataforma.
- **Comunicación técnica:** documentación clara de procedimientos, hallazgos y decisiones de diseño para facilitar la trazabilidad del trabajo.

8. Cronograma

Tipo	Fecha Inicio	Fecha Fin
Asignación de Proyecto	08 de abril	08 de abril

Elaboración	08 de abril	29 de abril
Calificación	01 de mayo	02 de mayo

9. Rúbrica de Calificación

9.1 Requisitos para optar a la calificación

Tema	Descripción	Cumple (Sí/No)
Cumplimiento del dataset y plataforma	El proyecto debe desarrollarse en Google BigQuery utilizando el dataset público NYC Taxi Trips 2022, con al menos 1 millón de registros.	
Uso de técnicas requeridas	Aplicación y evidencia de optimización y clustering obligatorio.	
Gestión y entregas del proyecto	El repositorio del curso debe incluir la carpeta Proyecto_2 con scripts SQL, evidencias, README e informe visual organizados correctamente.	
Documentación obligatoria	Debe contener descripción del dataset, transformaciones, optimización aplicada, hallazgos relevantes y enlace al informe visual.	
Evidencias y funcionalidad mínima	Análisis exploratorio y documentación.	

9.2 Resumen de Puntuaciones

Área	Puntos Totales	Puntos Obtenidos
1. Habilidades		
Conexión correcta al dataset (Uso correcto de un dataset público de al menos 1 millón de registros)	8	
Consultas SQL avanzadas y transformaciones (Aplicación de funciones agregadas, filtros, cálculos y limpieza de datos)	8	
Optimización con particiones y clustering	12	
Implementación correcta de al menos 2 modelos (de distinto tipo) con sintaxis SQL de ML	8	
Implementación y comparación entre modelos con distintas métricas de evaluación e hiperparámetros	12	
Manejo de Data Leakage con métodos distintos de Training y Evaluation Set	12	
Sub-Total Habilidades	60	
2. Conocimientos		
Análisis correcto de patrones y tendencias	10	
Visualización de resultados (visualización exploratoria y predicciones)	10	

Área	Puntos Totales	Puntos Obtenidos
Ingeniería de características (features derivadas y justificación de variables)	10	
Identificación correcta de variables de entrada, salida y propósito de cada modelo	5	
Comparación entre consultas estándar vs optimizadas (reducción de bytes procesados o tiempo de ejecución)	5	
Sub-Total Conocimientos	40	
TOTAL GENERAL	100	

9.3 Comentarios Generales

—

—

—

9.4 Detalle de la Calificación

No.	Criterio de evaluación	Punteo máximo	Satisfactorio (100 % – 61 %)	Necesita mejorar (60 % – 0 %)	Punteo obtenido
1	Habilidades	60			
1.1	Conexión correcta al dataset (Uso correcto de un dataset público de al menos 1 millón de registros)	8			
1.2	Consultas SQL avanzadas y transformaciones (Aplicación de funciones agregadas, filtros, cálculos y limpieza de datos)	8			

No.	Criterio de evaluación	Punteo máximo	Satisfactorio (100 % – 61 %)	Necesita mejorar (60 % – 0 %)	Punteo obtenido
	Rango del punteo:				
1.3	Optimización con particiones y clustering	12			
1.4	Implementación correcta de al menos 2 modelos (de distinto tipo) con sintaxis SQL de ML	8			
1.5	Implementación y comparación entre modelos con distintas métricas de evaluación e hiperparametros	12			

No.	Criterio de evaluación	Punteo máximo	Satisfactorio (100 % – 61 %)	Necesita mejorar (60 % – 0 %)	Punteo obtenido
1.6	Manejo de Data Leakage con métodos distintos de Training y Evaluation Set	12			
Sub-total Habilidades		60			
2	Conocimientos	40			
2.1	Análisis correcto de patrones y tendencias	20	Identifica y explica hallazgos relevantes en variables temporales, categóricas, geográficas o económicas.	Los hallazgos son superficiales, poco claros o no están sustentados por el análisis realizado.	
2.2	Visualización de resultados (visualización exploratoria y predicciones)				

No.	Criterio de evaluación	Punteo máximo	Satisfactorio (100 % – 61 %)	Necesita mejorar (60 % – 0 %)	Punteo obtenido
2.3	Ingeniería de características (features derivadas y justificación de variables)				
2.4	Identificación correcta de variables de entrada, salida y propósito de cada modelo				

No.	Criterio de evaluación	Punteo máximo	Satisfactorio (100 % – 61 %)	Necesita mejorar (60 % – 0 %)	Punteo obtenido
2.5	Comparación entre consultas estándar vs optimizadas (reducción de bytes procesados o tiempo de ejecución)				
Sub-total Conocimientos		40			
Total General		100			